

论文计划及开题报告

计划论文题目		基于生成式模型的生物医学关系抽取研究	
选题来源 选择打（√）	1、国家计委、科委项目（ ）；	5、主管部门（部委级）项目（ ）；	预 计
	2、国家经贸委项目（ ）；	6、省，市，自治区项目（ ）；	经 费
	3、国家自然科学基金项目（ ）；	7、校级项目（ ）；	约 元
	4、国务院其它部委项目（ ）；	8、自选项目（√）；9、其它（ ）。	
预计完成日期		2027 年 5 月	
主要内容（参考下列几方面） 1. 论文的选题依据，本课题在国内外的研究动态； 2. 课题在理论或实际应用方面的意义、价值以及可能达到的水平； 3. 本人对此课题开展研究的设想，拟解决哪些重点问题； 4. 工作计划，技术路线，实验方案，预期结果； 5. 预计工作量及进度安排。 计划及报告具体内容： 一、选题依据及国内外研究动态 1.1 选题依据 随着医学信息学与生物医学研究的快速发展，生物医学文本知识正在以前所未有的速度增长。以 PubMed 为例，作为全球最大的生物医学文献数据库，其每天新增上千篇同行评审论文，累计文档已超过 3600 万篇^[1]。这些文献中蕴含着大量关于基因、蛋白质、药物、疾病及其相互作用的宝贵知识，是药物研发、临床决策与医学知识图谱构建的重要来源。然而，相关知识多以非结构化的自然语言形式存在，依赖于专家的手工整理与提取，不仅成本高，周期长，也难以跟上文献的增长速度。因此，自动化的生物医学关系抽取（BioRE）技术成为连接海量文本与结构化知识的关键路径。 生物医学关系抽取（BioRE）旨在从非结构化的医学文本中自动识别并提取出结构化的实体关系的三元组。传统的 BioRE 主要依赖于机器学习方法，需要专家构建特定的规则，准确性高但泛化性低，难以适应新的数据场景；随着深度学习的兴起，BioRE 经历了从传统的流水线抽取到联合抽取框架的演变，有效缓解了错误传播问题；与此同时，基于 BERT 等预训练模型的判别式方法也显著提高了关系抽取的性能。 值得注意的是，生物医学文本中的关系抽取往往不是单一关系分类这一简单问题，而是普遍呈现复杂关系形态：生物医学文本句子长，结构难，常包含实体重叠与嵌套三元组、一个实体同时参与多个关系（“一对多”），以及多个实体对之间形成的复杂映射（“多对多”）。因此，这类复			

杂性使得上述判别式范式在输出结构表达方面更容易受限。相比之下，生成式模型，如序列到序列（Seq2Seq）模型利用编码器-解码器架构，将关系抽取视为“翻译”任务，能够以端到端生成的方式直接输出三元组集合，这天然地避免了设计复杂的特征工程，更适配关系的结构化表达。

此外，生物医学句子常包含复杂从句、被动语态等结构，仅依赖序列上下文往往难以捕捉实体间准确的语义联系，考虑到关系抽取天然地有着语言学的内在特点，因此本课题尝试结合句法知识，为生成式模型提供丰富的先验句法知识，辅助模型进一步理解文本中实体之间的内在关系，从而提高模型的抽取性能。

综合上述背景，本课题拟从以下三个方面开展研究：

首先，本课题拟构建高质量的句法结构知识，并针对生物医学长难句导致的依存弧噪声以及多解析器冲突，构建多解析器融合以及线性化算法，生成更可靠的依存结构表示，为生成式模型提供更稳定的结构知识。

其次，本课题进一步设想提出面向生成式模型 BioRE 的训练与优化方法，融合生成式模型的持续预训练阶段以及微调阶段。将高质量句法知识融入模型的持续预训练（Continuous Pre-training）阶段，设计结构感知的掩码策略。与传统的随机掩码策略不同，本研究将重点关注对于关系的掩码，以加强大模型对于关系的学习与判断。在此基础上，结合指令微调技术，训练模型端到端地生成符合规范的三元组结构。

最后，本课题设想探索面向低资源场景的情景学习方式，以解决生物医学领域数据稀缺导致的泛化性问题。通过情景学习，设计结构检索算法，在推理阶段检索，将与待预测句子在句法拓扑结构上高度相似的样本作为示例，并通过构建对应提示词（Prompt），引导模型进行类比推理，使其具备识别新型关系的能力，以提高模型的泛化性和鲁棒性。

综上所述，本研究将利用生成式的独特能力，通过引入句法知识和情景学习机制，期望在生物医学场景下实现更具泛化性和鲁棒性的关系抽取，推动该领域的发展。

1.2 国内外研究动态

生物医学关系抽取旨在从文本中自动识别并提取出具有特定语义关系的实体对。例如，从句子“*Aspirin significantly reduces the risk of myocardial infarction*”中，系统需要识别出“*Aspirin*”为药物，“*myocardial infarction*”为疾病，并判定二者之间存在“*Treats*（治疗）”或“*Prevents*（预防）”的语义关系。该任务主要经历了从机器学习方法，深度学习方法以及序列到序列模型的发展历程。

（1）判别式抽取范式

在深度学习之前，生物医学关系抽取主要依赖于传统的有监督机器学习方法。这一阶段的重点

是特征工程，即人为将非结构化的文本转为机器可读的特征。例如，Zhou 等人提出了一种基于 SVM 的经典方法^[2]，证明了通过结合基础的短语结构和词汇信息，能够显著提升关系抽取的性能；Bunescu 和 Mooney 提出了最短依存路径核（Shortest Path Dependency Kernel），他们认为两个实体之间的最短依存路径包含了描述二者关系最核心的信息，这一改进在提升计算效率的同时也优化了抽取效果^[3]。Miwa 等人则进一步结合了由多个句法解析器生成的特征，提出了一种复合核方法，在多个生物医学语料库上取得了当时的最佳性能^[4]。尽管早期的机器学习方法在当时取得了显著进展，但他们的特征设计高度依赖人工、且泛化能力差，存在着明显局限。

随后的深度学习方法为关系抽取带来了新的范式。Zeng 等人率先提出了基于卷积神经网络的关系抽取模型，通过最大池化层提取句子中最重要的特征，显著提升了关系分类的性能^[5]。受此启发，Liu 等人将 CNN 模型迁移至生物医学领域，针对药物-药物相互作用（DDI）任务，提出了一种基于依存句法路径的卷积神经网络，证明了深度学习模型在处理生物医学文本时的有效性^[6]。随后，为了捕捉句子中的长距离依赖关系，Sahu 和 Anand 设计了一种基于双向 LSTM 的模型用于提取药物相互作用，该模型无需复杂的句法解析即可有效捕捉实体间的长距离依赖^[7]。尽管深度的学习的方不再依赖人工特征，但他需要大量的标注数据，无法处理复杂关系情况，且存在着黑盒的难以解释的情况。

2019 年，Devlin 等人提出的 BERT 模型通过在大规模通用语料上进行掩码语言模型（MLM）预训练，显著提升了多项 NLP 任务的基准性能^[8]。然而，由于生物医学文本包含大量专业术语，直接将通用领域的 BERT 应用于该领域的效果并不突出。因此，Lee 等人提出了 BioBERT，该模型在 BERT 的基础上，利用 PubMed 和 PMC 的大规模生物医学语料进行了持续预训练（Continual Pre-training）。实验表明其在生物医学关系抽取任务上，性能显著优于通用 BERT^[9]。随后 Gu 等人提出了 PubMedBERT，直接利用生物医学语料从零开始对模型进行预训练，并构建了领域专用的词表^[10]。预训练语言模型的出现极大地加速了关系抽取领域的发展，取得了相当显著的成就。但其对标注数据高度依赖，且计算资源消耗巨大，与此同时其对复杂关系的抽取仍有待提升。

此外近年来也有研究关注于实体识别与关系抽取的结合--联合抽取。例如，Wei 等人提出的 CasRel 模型通过级联标注策略解决了实体重叠问题^[11]。联合抽取显著解决了误差传播带来的影响，强调了实体与关系之间的交互，提高了抽取性能。

综上所述，无论是早期的机器学习方法，到 BERT 模型，再到联合学习，本质上大多属于判别式框架。这些方法通常将关系抽取建模为分类或序列标注任务。因此高度依赖预定义的标签，泛化性差，且难以直接输出复杂的层级结构。

（2）生成式范式

近年来，随着编码器-解码器（Encoder-Decoder）架构与生成式模型的快速发展，关系抽取逐步从传统的判别式模型分类转向生成式模型的结构化生成。该范式将关系抽取视为一种“结构翻译”，模型输入自然语言句子，输出可解析的结构化三元组序列。Paolini 等人提出的 TANL 框架证明了利用 T5 等生成式模型，可以通过自然语言形式直接预测复杂的关系结构，这种端到端的生成方式有效地解决了传统流水线方法中的级联错误问题^[12]。在此基础上，Lu 等人提出的 UIIE 框架进一步统一了包括关系抽取、事件抽取在内的多种任务，通过设计特定的结构化模式语言，实现了端到端的结构生成^[13]。Yuan 等人发布了 BioBART 模型，该模型基于 BART 架构在海量生物医学语料上进行了生成式预训练，在多项生物医学生成与抽取任务上超越了基于 BERT 的判别式模型^[14]。Cabot 和 Navigli 提出了基于 BART 的 REBEL 模型，通过将关系三元组转换为文本序列，利用基于 BART 的序列到序列模型，简化了传统流程并取得了优异性能^[15]。

与此同时，针对生物医学领域普遍存在的低资源问题，基于大模型的情景学习（In-Context Learning, ICL）成为了新的研究热点。与传统微调不同，ICL 不更新模型参数，而是激发模型内在的知识进行类比推理。Chen 等人提出 KnowPrompt 方法，通过构建包含知识的提示模版，显著提升了低资源场景下的抽取性能^[16]。Wan 等人探索了 GPT-3 在信息抽取中的应用，发现通过合理设计检索增强策略，可以大幅提高大模型对特定领域关系的识别准确率^[17]。

尽管生成式模型的端到端性质使得关系抽取不再依赖于繁琐的规则设计，但其也存在一定局限：由于解码更自由，其在面对例如“一对多/多对多”映射时容易出现逻辑混乱、格式错误以及头尾实体顺序混淆等问题。生成式方法对结构的依赖更强，不同线性化格式、不同解码策略对结果影响显著，导致模型跨数据集/跨关系类型的鲁棒性仍不稳定，因此需要引入合适的 Schema 约束机制来提高输出一致性与可用性。

（3）依存句法知识与关系抽取

生物医学文本通常呈现长距离依赖、嵌套从句与被动结构等特点，仅依靠线性的上下文序列往往忽视了实体之间内在的语义关联。因此，考虑到关系抽取天然的内在语言学意义，许多研究试图通过引入规则的依存句法语言学知识，为关系抽取提供结构先验。在早期研究中，Bunescu 和 Mooney 提出了“最短依存路径（SDP）”假设，认为两个实体在依存树中的最短路径集中了表达两者关系最核心的谓词信息^[3]；Fundel 等人开发了基于依存解析树规则的 RelEx 系统，专门用于提取基因与蛋白质的相互作用，证明了句法结构对于处理生物医学复杂句式的有效性^[18]；随着深度学习的发展，图神经网络（Graph Neural Networks, GNN）成为了融合句法信息的首选架构。Zhang 等人提出的

C-GCN 模型将依存树转化为邻接矩阵，利用图卷积网络直接在依存结构上进行特征聚合，有效解决了长距离依赖问题^[19]。随后，针对生物医学文本中依存分析工具可能产生的解析错误，Guo 等人提出了基于注意力引导的图卷积网络（AGGCN），能够自动学习和筛选依存树中的关键子结构，从而降低了噪声对抽取精度的影响^[20]。

目前结合依存分析辅助关系抽取的方法大多仍局限于判别式抽取范式，将依存句法真正与生成式模型结合的研究仍缺乏系统化研究。此外，生物医学领域的依存解析器可能产生错误依存弧。多解析器虽能提供互补信息，也带来了拓扑冲突问题。若简单拼接或线性化容易造成序列过长、有效信息被冗余淹没，因此需要对齐融合并控制噪声的算法设计。

综上所述，生物医学关系抽取领域经历了从传统机器学习到深度神经网络，再到预训练语言模型的发展。传统判别式方法本质上是分类范式，高度依赖于预定义标签，难以表达复杂层级结构，跨数据集与跨关系类型泛化受限；新型生成式模型虽然为关系抽取带来了新的范式，但易出现格式错误与头尾混淆等问题，导致鲁棒性降低；依存句法知识虽有助于刻画长距离依赖，促进关系抽取的性能提升，但其解析往往存在噪声，多解析器引入也会出现拓扑冲突，需要合适的融合策略。因此，如何在引入句法知识的背景下，充分利用生成式模型的结构化生成能力，并通过情景学习提升模型在低资源场景下的泛化能力，是本课题所要研究的重点。

二、研究目标及意义

2.1 研究意义

医学文本关系抽取是把文献中的领域专业非结构化知识转化为可计算的结构化知识的关键环节，可直接支持药物研发、药物不良反应以及知识图谱构建等下游应用。在生物医学文献持续快速增长的背景下，如何从海量非结构化文本中精准、高效地抽取关键知识，已成为生物医学信息学领域的核心挑战。传统判别式方法严重依赖标注数据、人力消耗大；其对复杂关系处理不佳，泛化性也不足。因此，本研究旨在探索更具灵活性且更具推理能力的关系抽取方法。通过结合语言学句法知识以及生成式模型模型，构建更具适应性的生成式关系抽取框架。这对推动自然语言处理技术与医学信息学技术发展都有着实际意义。

（1）理论意义

生成式模型大多依赖海量数据驱动的建模，本研究将尝试引入语言学句法知识，探讨在数据驱动时代句法指导对模型性能的影响；与此同时，尽管生成式模型具备强大的生成能力，但在生物医学关系抽取中往往缺乏对句法结构与关系 schema 的显式建模与约束。因此，本研究将从句法结构注入、结构推动的持续预训练以及检索增强的解码约束三个方面给出系统性的方法论。

面对树（图）-序列的结构转化问题，将重点研究多解析器一致的依存结构去噪融合与线性化算法，实现拓扑结构的对齐；设计合适的依存标签掩码策略，促使生成式模型稳定学习句法关系；在推理层面，研究结构检索增强的情景学习（ICL）选择算法，引导模型进行结构类比推理。

（2）实际应用意义

在实际应用中，本研究面向药物不良反应、药物相互作用、医学知识图谱构建等需求，为下游检索问答与临床决策支持提供可靠的知识来源，显著降低人工整理与标注成本；此外，基于结构检索增强的情景学习（ICL）可在新关系场景下识别并扩展新型关系，为临床决策等更新提供更及时的知识支撑。

2.2 可能达到的水平

经过文献阅读和方法设计综合考量，本研究预计能达到以下水平：

（1）以生成式模型为主体，在公开生物学关系抽取基准数据集上完成对照评测，相较基线取得性能提升。

（2）通过引入结构掩码与多视角集成，预期降低生成式 BioRE 的幻觉与结构错误；

（3）形成依存融合算法与结构检索算法两类核心算法模块。

三、研究设想及重难点

3.1 研究设想

本课题基于句法感知的生成式生物学关系抽取总体框架，主要研究以下三个方面：基于多视角依存结构的生物学关系抽取研究、基于生成式模型的生物学关系抽取研究以及基于情景学习的生物学关系抽取研究。具体的研究任务包括设计依存结构的对齐与线性化算法；设计基于生成式模型的持续预训练与微调的模型优化方法；设计结构检索增强的情景学习算法与解码约束。并评估不同序列模型在该框架下的性能表现。




图 1 课题研究内容框架

(1) 研究内容一：基于多视角依存结构的生物医学关系抽取研究

为缓解生物医学文本长难句导致的依存解析误差累积，本研究将重点研究依存句法知识的去噪与融合。将对同一句子使用多种主流依存解析器得到多视角依存图，设计依存弧对齐与融合算法，从而得到更可靠的依存结构。并设计可控的线性化策略，将去噪后的依存图转化为可控的线性序列，形成可靠的算法模块，为后续生成式模型的预训练提供高质量的依存知识。

(2) 研究内容二：基于生成式模型生物医学关系抽取研究

本研究探索“结构驱动的持续预训练+指令微调”的生成式模型优化方法。首先在线性化后的依存知识基础上，设计一种结构掩码策略。不同于随机掩码策略，该方法将依存目标词与依存关系标签都纳入掩码集合，并提高对实体对之间关键依存路径的掩码概率，强迫模型根据上下文学习到关于句子的句法结构。利用大规模掩码的序列化生物医学语料对模型进行持续预训练的，使其更加熟悉医学文本词与词之间的关系；在下游 BioRE 标注数据上，设计合适 schema 策略，微调模型端到端生成符合规范的三元组序列，提升模型关系抽取的性能。

(3) 研究内容三：基于情景学习的生物医学关系抽取研究

针对真实应用中“新疾病/新药物关系缺乏标注、难以大规模微调”的低资源场景，本研究拟在

不更新参数的前提下，引入结构检索增强的情景学习（ICL）来提升新关系与少样本条件下的推理与泛化能力。具体而言，将候选示例的句法结构，编码为可检索的向量；根据预测句子，计算结构相似度与语义相似度以此选择最优示例，并按照统一 schema 形成上下文提示，引导模型进行结构类比推理，从而提升模型在少样本、低资源场景下的鲁棒性。

最后，本研究将计划对不同类型的生成式模型进行对比实验，找到最适合本框架的解决方案。本研究将对经典的 Encoder-Decoder 架构（如 T5, BART），目的是探究哪种模型结构能够更适应本研究框架，提升关系抽取的性能。

3.2 拟解决的关键问题

本研究旨在通过生成式模型解决提高生物医学关系抽取的性能，在数据构建、模型训练及推理应用的全流程中，拟重点攻克以下四个关键科学与技术问题：

（1）多源依存视角的噪声控制与对齐

生物医学文本长难句多、术语密集，单一的依存解析器（如 Stanza）容易产生错误依存弧。引入多解析器虽能提供互补信息，但同时也会带来边冲突，拓扑结构不一致等噪声问题，直接线性化会导致序列过长从而淹没关键结构信息。因此，研究将重点关注依存图输出的噪声过滤、对齐融合以及可控的线性化方法，为后续模型持续预训练与解码提供稳定的结构先验知识。

（2）如何设计良好的结构掩码策略

将依存句法线性化后直接作为模型输入进行持续预训练，并不必然意味着模型会真正掌握句法结构。关系抽取更依赖于依存关系类型与关键路径，而非单纯的依存词。因此，必须设计出一种良好的掩码策略，强迫模型通过上下文去更多地学会词与词之间的关系，从而真正高效地利用好显式的依存知识。此外，在持续预训练的过程中，还要把握好依存知识的度。如果将过多的依存知识都注入模型，那么可能导致模型过多的去学习句法类的知识，导致模型原有的文本输出能力下降。因此拟设计出良好的掩码策略，在句法知识与模型通用的知识之间做到平衡。

（3）低资源场景下的推理

情景学习的核心在于类比，但在生物医学领域，新型关系（如新发现的药物副作用）往往缺乏足够的标注数据。现有示例检索/选择方法多依赖词汇语义相似度，往往会导致语义相像但结构不像，从而无法为模型提供可复用的关系表达模板。因此拟设计结构检索算法。由于该结构算法同时利用句子的句法结构知识，因此需要设计好对于语义影响的平衡；与此同时，提示词（Prompt）的设计对大模型的输出结果至关重要，因此需精心设计与当前任务框架相匹配的提示词，从而提高情景学习的鲁棒性。

（4）解码的一致性

生成式模型本质上更加自由，在处理例如“一对多”或“多对多”的复杂映射时，容易产生逻辑混乱或格式错误，例如模型可能在生成三元组时混淆头尾实体的顺序。因此需要在指令微调阶段引入合适的 Schema 约束机制，以便让模型学会如何正确地表达关系。

四、工作计划，技术路线，实验方案，预期结果

4.1 工作计划与技术路线

（1）广泛学习文献：系统性地研究学习生物医学关系抽取、生成式语言模型、依存句法分析以及情景学习领域的国内外最新研究进展。重点分析现有的技术方案的优缺点，以及大模型在低资源场景下的推理机制，为后续实验提供坚实的理论基础。

（2）构建多视角依存知识融合与线性化算法：收集并整理生物医学领域的大量文献摘要。针对原始文本，利用多种依存句法分析工具进行解析，获取多视角的依存结构知识。设计对应去噪融合算法，对不同工具生成的依存标签进行对齐以及可控线性化操作。

（3）以多视角依存知识融合与线性化算法为基础，结合结构掩码策略，对模型持续预训练与指令微调进行流程设计；设计合适的 schema 解码约束，训练模型能够根据自然语言，端到端地生成符合规范输出结构。

（4）针对少样本场景，设计结构检索增强算法。利用向量化计算预测句子与数据库示例句子的结构相似度，将检索到的高相似结构样本作为思维链的一部分输入模型，引导模型在无需参数更新的情况下进行结构类比推理。

（5）搭建整体技术框架，完成编程实现与系统设计。并不断进行算法设计与优化。

4.2 实验方案及以预期结果

（1）实验数据准备：使用公开基准数据集与构建的数据集作为实验对象，并针对低资源场景构建不同规模的 N-shot 数据集，以模拟真实的少样本应用场景，确保数据的多样性与代表性。

（2）实验设计

1.模型对比实验：在统一输入输出 schema 预训练下，对比不同生成式模型在本研究框架下的性能表现。

2.消融实验：验证依存结构知识注入的有效性、其多视角集成融合与单视角分析的差异，以及结构掩码与随机掩码的预训练效果差异。

3.低资源场景学习对比实验：验证本研究的结构化检索方案在少样本下的性能，以评估模型的泛化能力。

(3) 实验实施：利用不同规模大模型进行实验；调整依存融合线性化算法、结构掩码策略以及结构检索算法，不断优化实验效果。

(4) 实验结果分析与总结：从准确性、泛化性等方面对实验结果进行定量分析；撰写详细的实验报告并形成可推广的研究成果。

(5) 成果验证与应用推广：开发可视化的生物医学关系抽取系统，支持输入原始医学文本，展示依存分析结果、结构化序列以及最终抽取的实体关系三元组；并对实验中提出的改进方法进行最终评估与调整。




图 2 课题实验方案及预期结果图

五、研究工作量及进度安排

- 2025.10—2025.11：查阅相关文献，完成开题报告。
- 2026.01—2026.03：收集生语料，研究依存融合算法。
- 2026.03—2026.05：设计结构感知的掩码策略进行模型持续预训练，并结合指令微调技术优化模型的生成效果。
- 2026.05—2026.07：研究面向低资源场景的结构检索算法，实现情景学习并得出实验结果。
- 2026.07—2026.10：开展模型对比实验，并进行消融分析与参数优化。
- 2026.10—2026.11：整合所有阶段的研究成果，并与其他方案进行比较
- 2026.11—2027.05：整理已有实验成果和技术方案，撰写并完成论文，参加答辩。

参考文献

[1] Chen, Qingyu, et al. "Benchmarking large language models for biomedical natural language processing

-
- applications and recommendations." *Nature communications* 16.1 (2025): 3280.
- [2] Zhou, GuoDong, et al. "Exploring various knowledge in relation extraction." *Proceedings of the 43rd annual meeting of the association for computational linguistics (acl'05)*. 2005.
- [3] Bunescu, Razvan, and Raymond Mooney. "A shortest path dependency kernel for relation extraction." *Proceedings of human language technology conference and conference on empirical methods in natural language processing*. 2005.
- [4] Miwa, Makoto, et al. "A rich feature vector for protein-protein interaction extraction from multiple corpora." *Proceedings of the 2009 conference on empirical methods in natural language processing*. 2009.
- [5] Zeng, Daojian, et al. "Relation classification via convolutional deep neural network." *Proceedings of COLING 2014, the 25th international conference on computational linguistics: technical papers*. 2014.
- [6] Liu, Shengyu, et al. "Drug-drug interaction extraction via convolutional neural networks." *Computational and mathematical methods in medicine* 2016.1 (2016): 6918381.
- [7] Sahu, Sunil Kumar, and Ashish Anand. "Drug-drug interaction extraction from biomedical texts using long short-term memory network." *Journal of biomedical informatics* 86 (2018): 15-24.
- [8] Devlin, Jacob, et al. "Bert: Pre-training of deep bidirectional transformers for language understanding." *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*. 2019.
- [9] Lee, Jinhyuk, et al. "BioBERT: a pre-trained biomedical language representation model for biomedical text mining." *Bioinformatics* 36.4 (2020): 1234-1240.
- [10] Gu, Yu, et al. "Domain-specific language model pretraining for biomedical natural language processing." *ACM Transactions on Computing for Healthcare (HEALTH)* 3.1 (2021): 1-23.
- [11] Wei, Zhepei, et al. "A novel cascade binary tagging framework for relational triple extraction." *Proceedings of the 58th annual meeting of the association for computational linguistics*. 2020.
- [12] Paolini, Giovanni, et al. "Structured prediction as translation between augmented natural languages." *arXiv preprint arXiv:2101.05779* (2021).
- [13] Lu, Yaojie, et al. "Unified structure generation for universal information extraction." *arXiv preprint arXiv:2203.12277* (2022).
- [14] Yuan, Hongyi, et al. "BioBART: Pretraining and evaluation of a biomedical generative language model." *arXiv preprint arXiv:2204.03905* (2022).
- [15] Cabot, Pere-Lluís Huguet, and Roberto Navigli. "REBEL: Relation extraction by end-to-end language generation." *Findings of the association for computational linguistics: emnlp 2021*. 2021.
- [16] Chen, Xiang, et al. "Knowprompt: Knowledge-aware prompt-tuning with synergistic optimization for relation extraction." *Proceedings of the ACM Web conference 2022*. 2022.
- [17] Wan, Zhen, et al. "Gpt-re: In-context learning for relation extraction using large language models." *arXiv preprint arXiv:2305.02105* (2023).
- [18] Fundel, Katrin, Robert Küffner, and Ralf Zimmer. "RelEx—Relation extraction using dependency parse trees." *Bioinformatics* 23.3 (2007): 365-371.
- [19] Zhang, Yuhao, Peng Qi, and Christopher D. Manning. "Graph convolution over pruned dependency trees improves relation extraction." *arXiv preprint arXiv:1809.10185* (2018).
- [20] Guo, Zhijiang, Yan Zhang, and Wei Lu. "Attention guided graph convolutional networks for relation extraction." *arXiv preprint arXiv:1906.07510* (2019).